

Grado en Ingeniería Informática

11 de octubre de 2024

*Inteligencia Artificial en las Organizaciones*

## “Práctica 1”

---

Álvaro Guerrero Espinosa (100472294)

César López Mantecón (100472092)

Paula Subías Serrano (100472119)

Irene Subías Serrano (100472108)



Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento - No Comercial - Sin Obra Derivada**



## ÍNDICE GENERAL

1. INTRODUCCIÓN. . . . .	1
2. DESCRIPCIÓN DE LOS DATOS . . . . .	2
3. PROCESO DE ENTRENAMIENTO . . . . .	3
3.1. Parte 1 . . . . .	3
3.2. Parte 2 . . . . .	6
4. VISUALIZACIÓN DE RESULTADOS . . . . .	10
4.1. Parte 1 . . . . .	10
4.2. Parte 2 . . . . .	11
5. COMPARACIÓN DE RESULTADOS . . . . .	12
5.1. Entrenamiento . . . . .	12
5.2. Predicción. . . . .	12
5.3. Conclusiones sobre los resultados . . . . .	14
6. CONCLUSIÓN . . . . .	15
BIBLIOGRAFÍA . . . . .	16



## ÍNDICE DE FIGURAS

3.1	Matriz de resultados <i>t-test</i> - parte 1 . . . . .	5
3.2	Error de cada modelo y error medio según <i>loss function</i> . . . . .	5
3.3	Matriz de resultados <i>t-test</i> - parte 2 . . . . .	7
3.4	Errores de los modelos - parte 2 . . . . .	8
3.5	Errores agrupados por windowing . . . . .	8
4.1	Valores anteriores y predichos por el modelo - parte 1 . . . . .	10
4.2	Valores anteriores y predichos por el modelo - parte 2 . . . . .	11
5.1	Valores predichos vs valores reales . . . . .	13
5.2	Error absoluto por semana de cada modelo . . . . .	14



## ÍNDICE DE TABLAS

3.1	Errores de los diferentes modelos - parte 1 . . . . .	4
3.2	Errores del modelo 2 . . . . .	5
3.3	Errores de los diferentes modelos - parte 2 . . . . .	6
3.4	Errores del modelo 7 . . . . .	9
5.1	Predicciones de los modelos y valores reales . . . . .	13
5.2	Error de las predicciones . . . . .	13





# 1. INTRODUCCIÓN

En este documento se recoge el desarrollo de la primera práctica de *Inteligencia Artificial en las Organizaciones*. En esta práctica obtendremos dos modelos de *redes neuronales* para la predicción del nivel de agua en un embalse de la cuenca del Miño-Sil. Para ello, seguiremos dos aproximaciones: en la primera obtendremos un modelo entrenando mediante una validación cruzada aleatoria, en la segunda usaremos una validación cruzada basada en series temporales. Todo el estudio se llevará a cabo en la herramienta [Altair AI Studio](#). El uso de redes neuronales para este problema presenta claras ventajas gracias a las características de esta clase de modelos:

- **Buenos resultados en regresión:** los modelos basados en RNA han demostrado ser muy eficaces a la hora de obtener predicciones.
- **No linealidad:** el nivel de agua en los embalses sigue un comportamiento no lineal. Los modelos basados en RNA son capaces de operar con este tipo de datos, obteniendo buenos resultados.
- **Robustez:** el conjunto de datos presenta una gran variabilidad, dado que depende de multitud de factores. Las RNA son capaces de operar y realizar predicciones a partir de datos con ruido o incompletos.

La gestión de los embalses ha adquirido mucha importancia en los últimos años, en especial de la mano con la Agenda 2030. Los embalses cuentan con multitud de usos relacionados con las necesidades básicas de la población: abastecimiento de agua potable, riego agrícola, producción de energía renovable, preservación del medio ambiente, uso como cortafuegos y gestión de riesgo de inundaciones. Para llevar a cabo estas funciones es necesaria una administración cuidadosa y eficaz de los mismos [1].

Además, la producción de energía limpia es uno de los principales problemas que atañe a la población en la actualidad. Los embalses, junto con otras fuentes de energía renovable, presentan un gran potencial para la producción eléctrica. En España, según un informe del Ministerio de Industria, Energía y Turismo de 2015 [2], la energía hidráulica supone casi un 2 % de la energía total consumida en el país. Esto implica que es la tercera fuente energética renovable más utilizada en España.

Con esto, hemos hecho un breve repaso sobre la importancia de una correcta gestión de los embalses en España debido a la multitud de funciones básicas que cubren. Un sistema capaz de predecir los niveles de agua en los embalses podría ser de gran utilidad de cara a la anticipación frente a épocas de sequía u otras calamidades. También, el uso de redes de neuronas artificiales presenta claras ventajas para tratar de atajar este problema.

## 2. DESCRIPCIÓN DE LOS DATOS

Los datos usados se componen del agua total y actual en cada semana de 10 embalses cercanos entre sí de la cuenca del Miño-Sil a lo largo de aproximadamente 35 años. También se tiene el nombre de cada embalse y si se usan para producción eléctrica. A partir de estos datos se han obtenido otros derivados: cambio semanal del agua actual, tasa de cambio (porcentual), y promedio móvil del agua actual en las últimas 4 semanas. Además, se eliminaron los atributos de producción eléctrica y nombre de la cuenca, ya que son constantes y por lo tanto no deberían influir en la precisión del modelo obtenido. Eliminar estos atributos permite obtener modelos más simples y rápidos. El valor objetivo a predecir es el **agua en la siguiente semana**, atributo que se ha añadido al set de datos.

En la parte 1 se tratarán los datos como una serie no temporal para regresión. Cabe destacar que, como los datos realmente representan una serie temporal, tratarlos como una serie no temporal para hacer regresión puede introducir algunos problemas de *data leak*.

En la parte 2 se tratarán los datos como una serie temporal. Debido a esto se asumirá que el agua actual durante las últimas semanas es suficiente para predecir el agua actual en semanas futuras.

### 3. PROCESO DE ENTRENAMIENTO

Con el fin de hacer un experimento reproducible se ha utilizado la opción de usar un único hilo con semilla local en el entrenamiento de la red neuronal. La semilla empleada ha sido 1992.

Antes de continuar, destacamos que al tratar de replicar el experimento en un equipo distinto no hemos logrado obtener exactamente los mismos resultados. Si bien es cierto que el comportamiento general de los modelos ha sido el mismo, los valores obtenidos varían.

#### 3.1. Parte 1

Para el entrenamiento de distintos modelos trabajaremos con variaciones sobre 3 parámetros de la red neuronal (número de capas ocultas, *loss function* y *learning rate*). Además, tendremos dos grupos de modelos: la mitad filtrará el dato *Agua\_total*, generalmente constante para un embalse; y la otra mitad utilizará todos los atributos. Esto resulta en 16 modelos distintos. También incluiremos un modelo extra con los valores por defecto como modelo de control.

De esta forma, estamos empleando un *grid-search* con los siguientes valores:

- Filtrado de datos:  $\{all, exclude\ agua\ total\}$ .
- Número de capas:  $\{2, 8\}$ .
- *loss function*:  $\{absolute, Huber\}$ .
- *learning rate*:  $\{0,01, adaptive\}$ .

Al concluir el entrenamiento hemos obtenido los siguientes resultados:

Modelo	Parámetros	RMSE
0	( <i>default</i> )	3.933
1	( <i>all, adaptative, 2, absolute</i> )	4.220
2	( <i>all, adaptative, 2, Huber</i> )	3.928
3	( <i>all, adaptative, 8, absolute</i> )	4.609
4	( <i>all, adaptative, 8, Huber</i> )	4.115
5	( <i>all, 0.01, 2, absolute</i> )	4.351
6	( <i>all, 0.01, 2, Huber</i> )	3.931
7	( <i>all, 0.01, 8, absolute</i> )	4.491
8	( <i>all, 0.01, 8, Huber</i> )	4.011
9	( <i>exclude agua total, adaptative, 8, absolute</i> )	4.657
10	( <i>exclude agua total, adaptative, 8, Huber</i> )	4.236
11	( <i>exclude agua total, adaptative, 2, absolute</i> )	4.145
12	( <i>exclude agua total, adaptative, 2, Huber</i> )	3.981
13	( <i>exclude agua total, 0.01, 8, absolute</i> )	4.542
14	( <i>exclude agua total, 0.01, 8, Huber</i> )	4.108
15	( <i>exclude agua total, 0.01, 2, absolute</i> )	4.574
16	( <i>exclude agua total, 0.01, 2, Huber</i> )	3.970

TABLA 3.1. ERRORES DE LOS DIFERENTES MODELOS - PARTE 1

Al realizar un test de significancia estadística (Anova) obtenemos el siguiente resultado:

Anova Test: ( $f = 1,455$ ,  $\text{prob} = 0,124$ ,  $\alpha = 0,050$ )

Con nuestros datos y haciendo uso de una tabla para la distribución de  $f$  [3] podemos ver que el valor crítico de  $f$  se encuentra en el rango (1,5705, 1,6664). El valor de  $f$  obtenido es inferior a este rango, y el  $p$ -value obtenido es mayor que  $\alpha$ . Teniendo en cuenta todo lo anterior podemos concluir que **no existe evidencia suficiente para afirmar que los modelos obtenidos sean distintos** [4].

Si observamos la comparación por pares proporcionada por el  $t$ -test, destaca el modelo 9 por ser el que presenta diferencias más significativas con el resto de modelos. A continuación se muestra la matriz resultante de la ejecución del test:

	3.933 +/- ...	4.220 +/- ...	3.928 +/- ...	4.609 +/- ...	4.115 +/- ...	4.351 +/- ...	3.931 +/- ...	4.491 +/- ...	4.011 +/- ...	4.657 +/- ...	4.236 +/- ...	4.145 +/- ...	3.981 +/- ...	4.542 +/- ...	4.108 +/- ...	4.574 +/- ...	3.970 +/- ...
3.933 +/- ...		0.341	0.988	0.050	0.562	0.191	0.995	0.068	0.791	0.033	0.340	0.543	0.880	0.054	0.566	0.074	0.905
4.220 +/- ...			0.362	0.208	0.714	0.650	0.367	0.313	0.436	0.147	0.957	0.817	0.423	0.249	0.687	0.275	0.387
3.928 +/- ...				0.059	0.573	0.210	0.994	0.083	0.791	0.040	0.358	0.552	0.875	0.067	0.578	0.084	0.898
4.609 +/- ...					0.130	0.416	0.060	0.690	0.057	0.882	0.247	0.195	0.065	0.824	0.116	0.920	0.055
4.115 +/- ...						0.437	0.579	0.190	0.713	0.090	0.690	0.929	0.667	0.151	0.981	0.178	0.631
4.351 +/- ...							0.213	0.616	0.237	0.323	0.704	0.544	0.242	0.509	0.411	0.503	0.215
3.931 +/- ...								0.085	0.798	0.041	0.363	0.557	0.882	0.068	0.584	0.086	0.905
4.491 +/- ...									0.077	0.564	0.369	0.285	0.091	0.849	0.169	0.791	0.075
4.011 +/- ...										0.035	0.432	0.676	0.919	0.061	0.723	0.087	0.885
4.657 +/- ...											0.181	0.146	0.043	0.696	0.078	0.907	0.035
4.236 +/- ...												0.789	0.418	0.298	0.665	0.317	0.384
4.145 +/- ...													0.636	0.233	0.911	0.249	0.605
3.981 +/- ...														0.073	0.675	0.094	0.972
4.542 +/- ...															0.134	0.919	0.059
4.108 +/- ...																0.163	0.638
4.574 +/- ...																	0.081
3.970 +/- ...																	

Fig. 3.1. Matriz de resultados *t-test* - parte 1

El modelo 9 cuenta con un RMSE anormalmente alto de  $4,657 \pm 0,686$ . También podemos observar que existen 2 clases de modelos donde el principal componente diferenciador es la *loss function*: la función *Huber* presenta, en general, un error más bajo que los modelos con la función *absolute* con los mismos parámetros. Esto se puede comprobar a través de los siguientes gráficos:




Fig. 3.2. Error de cada modelo y error medio según *loss function*

Con toda esta información concluimos que el mejor modelo y con el que haremos la predicción es el modelo 2, debido a que se trata de un modelo considerablemente sencillo (menor número de capas y valores por defecto) y con el menor error.

RMSE	$3,928 \pm 0,787$
Correlación	$0,998 \pm 0,001$
Absolute Error	$1,863 \pm 0,126$
Relative Error	$8,85 \% \pm 0,83 \%$
Normalized Absolute error	$0,043 \pm 0,03$
Squared Error	$15,987 \pm 6,767$
Root Relative squared error	$0,069 \pm 0,013$

TABLA 3.2. ERRORES DEL MODELO 2

### 3.2. Parte 2

Al igual que en la parte anterior, trabajaremos con variaciones sobre 2 parámetros para generar distintos modelos. Además, trabajaremos con distintos tamaños de ventana para el *Windowing* con el fin de comparar el impacto de distinto número de *lags* sobre la eficacia del modelo.

Los valores con los que trabajaremos en cada parámetro son los siguientes:

- *Windowing*: {4, 26, 52, 208}
- Número de capas: {2, 8}
- *loss function*: {*absolute*, *quadratic*}

Las posibles combinaciones de estos valores resultan en 16 modelos. No se ha podido usar la función *Huber*, pese a sus buenos resultados en la parte anterior, debido al excesivo tiempo de entrenamiento de los modelos. A continuación se muestran los resultados de la fase de entrenamiento:

Modelo	Parámetros	RMSE
0	( <i>default</i> )	10.249
1	(4, 2 <i>quadratic</i> )	9.581
2	(26, 2, <i>quadratic</i> )	10.305
3	(52, 2, <i>quadratic</i> )	9.199
4	(208, 2, <i>quadratic</i> )	9.097
5	(4, 8, <i>quadratic</i> )	9.170
6	(26, 8, <i>quadratic</i> )	9.223
7	(52, 8, <i>quadratic</i> )	8.789
8	(208, 8, <i>quadratic</i> )	9.248
9	(4, 2, <i>absolute</i> )	9.574
10	(26, 2, <i>absolute</i> )	10.462
11	(52, 2, <i>absolute</i> )	9.813
12	(208, 2, <i>absolute</i> )	9.330
13	(4, 8, <i>absolute</i> )	9.139
14	(26, 8, <i>absolute</i> )	11.127
15	(52, 8, <i>absolute</i> )	10.686
16	(208, 8, <i>absolute</i> )	10.884

TABLA 3.3. ERRORES DE LOS DIFERENTES MODELOS - PARTE 2

Destaca, aunque no quede registrada en la tabla, que la tolerancia de la medida no nos permiten depositar mucha confianza en estos datos ya que todas son del orden del 90 % del

valor medido. No obstante, con el fin de continuar con el estudio, usaremos las medidas obtenidas.

Siguiendo la misma metodología que en la parte anterior, si observamos los resultados del test *Anova* podemos afirmar que existen diferencias significativas en los modelos. Además, teniendo en cuenta el valor de *p-value* podemos concluir que los **modelos obtenidos son distintos**.

Anova test: ( $f = 11,523$ ,  $prob = 0,000$ ,  $\alpha = 0,050$ )

Esto lo podemos corroborar al observar la matriz resultante del *t-test*. Se aprecian varios pares de modelos que resultan distintos, con unos valores *p* muy cercanos a 0.

	10.249 +/- ...	9.581 +/- ...	10.305 +/- ...	9.199 +/- ...	9.097 +/- ...	9.170 +/- ...	9.223 +/- ...	8.789 +/- ...	9.248 +/- ...	9.574 +/- ...	10.462 +/- ...	9.813 +/- ...	9.330 +/- ...	9.139 +/- ...	11.127 +/- ...	10.686 +/- ...	10.884 +/- ...
10.249 +/- ...		0.033	0.846	0.000	0.000	0.000	0.000	0.000	0.001	0.035	0.471	0.118	0.002	0.000	0.004	0.147	0.044
9.581 +/- ...			0.021	0.197	0.127	0.200	0.233	0.008	0.298	0.984	0.006	0.446	0.441	0.164	0.000	0.001	0.000
10.305 +/- ...				0.000	0.000	0.000	0.000	0.000	0.000	0.022	0.594	0.076	0.001	0.000	0.007	0.205	0.066
9.199 +/- ...					0.694	0.816	0.824	0.096	0.854	0.214	0.000	0.016	0.626	0.826	0.000	0.000	0.000
9.097 +/- ...						0.807	0.637	0.239	0.588	0.141	0.000	0.008	0.413	0.887	0.000	0.000	0.000
9.170 +/- ...							0.850	0.175	0.796	0.214	0.000	0.026	0.600	0.919	0.000	0.000	0.000
9.223 +/- ...								0.087	0.929	0.251	0.000	0.025	0.699	0.763	0.000	0.000	0.000
8.789 +/- ...									0.083	0.010	0.000	0.000	0.046	0.206	0.000	0.000	0.000
9.248 +/- ...										0.318	0.000	0.040	0.774	0.714	0.000	0.000	0.000
9.574 +/- ...											0.006	0.442	0.462	0.177	0.000	0.001	0.000
10.462 +/- ...												0.023	0.000	0.000	0.033	0.467	0.191
9.813 +/- ...													0.086	0.018	0.000	0.003	0.000
9.330 +/- ...														0.526	0.000	0.000	0.000
9.139 +/- ...															0.000	0.000	0.000
11.127 +/- ...																0.183	0.465
10.686 +/- ...																	0.546
10.884 +/- ...																	

Fig. 3.3. Matriz de resultados *t-test* - parte 2

Para poder analizar mejor los modelos, utilizaremos un diagrama de barras que muestre el RMSE de cada uno. Gracias a la representación de cada valor junto con su tolerancia, podemos apreciar la mala calidad de la medición que aporta Altair AI Studio antes mencionada:

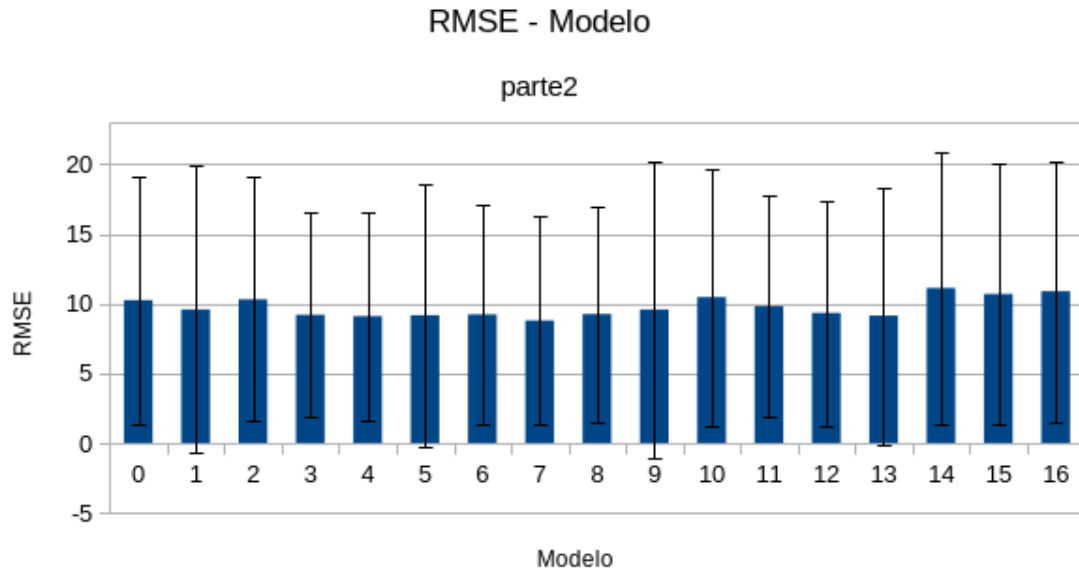


Fig. 3.4. Errores de los modelos - parte 2

Visualmente parece apreciarse un mejor comportamiento de los modelos que emplean 4 o 52 semanas en el *Windowing*. Al extraer el error medio agrupado por los valores de este parámetro podemos comprobar que esta hipótesis es **falsa**. No existen diferencias significativas entre los modelos con 4, 52 o 208 *lags*. Si que se aprecia un rendimiento peor en el caso de 26 *lags*.




Fig. 3.5. Errores agrupados por windowing

Con toda esta información y al no apreciar un mejor criterio de decisión, concluimos que el modelo que se usará para la predicción será el modelo 7 por tener el menor error. A



continuación se muestra una tabla con toda la información relativa a este modelo:

RMSE	$8,489 \pm 7,457$
Correlación	$0,000 \pm 0,000$
Absolute Error	$8,789 \pm 7,455$
Squared Error	$132,809 \pm 228,819$

TABLA 3.4. ERRORES DEL MODELO 7

No se han podido extraer más medidas por errores con el software de Altair. Destaca la baja correlación obtenida, en contraste con el buen resultado de las predicciones. Esto podría indicar que las predicciones podrían ser fruto de la casualidad. Para descartar esta hipótesis hemos decidido repetir el experimento con otra semilla distinta, obteniendo de nuevo una correlación de 0 y un buen comportamiento en las predicciones. Es por esto que concluimos que la baja correlación se debe a un error del software de Altair Ai Studio.

## 4. VISUALIZACIÓN DE RESULTADOS

Para la predicción de los datos se ha seleccionado el embalse **Bao**. Este embalse cuenta con variación significativa en el nivel de agua y apenas cuenta con datos faltantes. Es por esto que lo consideramos un buen candidato sobre el que realizar predicciones.

### 4.1. Parte 1

Para realizar la predicción ha sido necesario filtrar los datos eliminados para el entrenamiento del modelo (i.e. *Ámbito\_Nombre* y *Electrico\_flag*) y aislar los datos del embalse seleccionado para obtener los datos de la última semana.

Para predecir los datos de una semana son necesarios los datos de la semana anterior. Es por esto que cada vez que se realice una predicción se reinsertarán los resultados obtenidos para poder obtener la siguiente. Además, ha sido necesario introducir algunos datos manualmente como el promedio móvil de las últimas 4 semanas o la tasa de cambio.

A continuación se muestran en forma de gráfico las predicciones para 3 semanas junto con los datos inmediatamente anteriores:




Fig. 4.1. Valores anteriores y predichos por el modelo - parte 1

En el gráfico se muestran 4 semanas previas a la predicción, siendo la semana 0 la primera predicha por nuestro modelo.

Se puede observar que los datos tienen un fuerte cambio de tendencia, pasando de descender a oscilar entorno a un valor constante. Nuestro modelo mantiene esa segunda tendencia durante las 3 semanas predichas. Mas adelante, compararemos los resultados obtenidos con los valores reales.

## 4.2. Parte 2

Siguiendo la misma metodología que para la parte 1, hemos realizado las transformaciones necesarias sobre los datos para el correcto funcionamiento del modelo. Esto incluye filtrado de datos y *windowing*. Además, ha sido necesario reinsertar los nuevos datos predichos para poder predecir la semana próxima.

Con esto, hemos predicho el valor del nivel de agua en los embalses para 3 semanas. A continuación se muestra un gráfico de las 4 semanas previas a la predicción y las 3 semanas predichas:




Fig. 4.2. Valores anteriores y predichos por el modelo - parte 2

En este gráfico se aprecia un cambio de tendencia de los datos, de descendente a ascendente. Se tratan de predicciones muy distintas a las logradas en la primera parte. Más adelante se examirán y compararán con los valores reales.

## 5. COMPARACIÓN DE RESULTADOS

En este capítulo compararemos los resultados obtenidos en cada una de las partes. También evaluaremos el resultado de la predicción comparándolo con el valor real del nivel de agua en el embalse.

Para facilitar la comprensión se incluyen algunos detalles con respecto a los datos expuestos:

- Hablaremos de semanas 0, 1 y 2 como la primera, siguiente y última semana sobre las que obtendremos una *predicción*.
- Hablaremos de las semanas -1, -2... como las semanas previas o la anterior a la previa, respectivamente.
- El nivel de agua, así como las medidas del error que compartan sus unidades, siempre estará medido en *hectómetros cúbicos* ( $hm^3$ ).

### 5.1. Entrenamiento

Durante el entrenamiento destaca la inmensa diferencia entre los errores del primer y segundo modelo. Mientras que los modelos de la parte 1 tienen un error promedio de 4,22, los modelos de la parte 2 cuentan con un error medio de 8,76 <sup>1</sup>. Dada la naturaleza temporal de los datos, esto puede deberse a la existencia de *data leaks* durante el entrenamiento de la primera parte. De nuevo, es importante recordar que las medidas del error durante la parte dos son poco fiables debido a la gran tolerancia que presentan.

### 5.2. Predicción

Los valores predichos por el primer y segundo modelo son muy diferentes. Mientras que el primero mantiene una tendencia más o menos constante el segundo predice un aumento en el nivel de agua del embalse seleccionado. Colocando los resultados en una gráfica, junto con el nivel de agua real medido en esas fechas, podemos comprobar que el segundo modelo obtiene un resultado mucho mejor que el primero:

---

<sup>1</sup>Cálculos realizados para el RMSE




Fig. 5.1. Valores predichos vs valores reales

Se aprecia que el modelo de la segunda parte es capaz de predecir el aumento en el nivel de agua del embalse, mientras que el modelo de la primera parte erra por completo la predicción.

Haciendo uso de los datos en las siguientes dos tablas podemos observar que el primer modelo se aleja un promedio del 16.48 % del valor real, siendo las predicciones más cercanas en el tiempo a los datos mejores que las más alejadas. En cambio, el segundo modelo realiza una predicción con un error del 6.09 %, manteniéndose esta medida más o menos constante para las 3 semanas.

Datos	Semana 0 ( $hm^3$ )	Semana 1 ( $hm^3$ )	Semana 2( $hm^3$ )
Modelo parte 1	163.198	162.527	160.471
Modelo parte 2	165.374	186.258	197.378
Valores reales	181	197	206

TABLA 5.1. PREDICCIONES DE LOS MODELOS Y VALORES REALES

Error	Semana 0	Semana 1	Semana 2	Promedio
Error parte 1	17.802	34.473	45.529	32.601
Error relativo parte 1	9.84 %	17.5 %	22.10 %	16.48 %
Error parte 2	15.626	10.742	8.662	11.663
Error relativo parte 2	8.63 %	5.45 %	4.19 %	6.09 %

TABLA 5.2. ERROR DE LAS PREDICCIONES

### 5.3. Conclusiones sobre los resultados

Tras haber analizado los datos de las predicciones de ambos modelos podemos afirmar con rotundidad que la aproximación basada en series temporales muestra un mejor rendimiento. El modelo obtenido en la parte 2 ha sido capaz de realizar una predicción acertada del nivel de agua para el embalse seleccionado con un error mucho menor que el modelo obtenido en la primera parte. Esto se puede observar mejor en el siguiente gráfico:

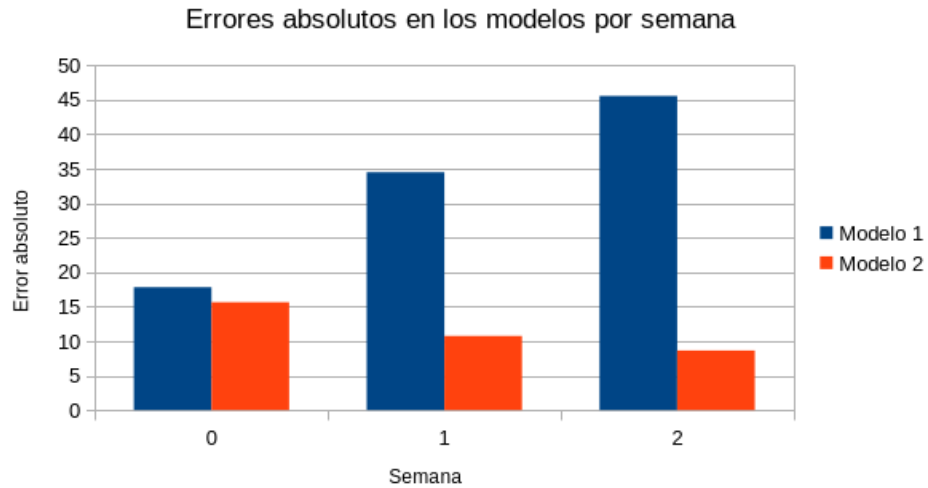


Fig. 5.2. Error absoluto por semana de cada modelo

Tal y como se especuló al principio del proyecto, el tratamiento de los datos como una serie temporal supone un mejor rendimiento debido a la ausencia de *data leaks* y la naturaleza de los datos.

## 6. CONCLUSIÓN

Esta práctica nos ha introducido al uso de herramientas especializadas en el trabajo con modelos de inteligencia artificial. Hemos encontrado el uso de estas herramientas útil debido al alto grado de abstracción que presenta, permitiendo que usuarios no experimentados en el mundo de la programación puedan aprovechar las ventajas de los algoritmos de *Machine Learning*. No obstante, los errores observados durante el desarrollo nos hacen pensar que su aplicación debería ser en proyectos de poca criticidad o con fines puramente didácticos.

Cabe destacar que la aplicación de estas herramientas a un problema presente en la actualidad motiva la obtención de buenos resultados y nos acerca cada vez más a aplicaciones reales de los conocimientos adquiridos durante nuestra carrera académica. El uso de la inteligencia artificial para la obtención de modelos a partir de grandes cantidades de datos presenta muchas aplicaciones en el mundo moderno, demostrando el potencial de esta herramienta en un gran abanico de ámbitos.

## BIBLIOGRAFÍA

- [1] Endesa, *Endesa*, <https://www.endesa.com/es/la-cara-e/centrales-electricas/para-que-sirven-embalses-usos-beneficios>, Consultado: 6 octubre, 2024, 2024.
- [2] G. de España, “La energía en España 2015,” Ministerio de Industria, Energía y Turismo, España, inf. téc., 2015, Consultado: 6 octubre, 2024. [En línea]. Disponible en: [https://www.miteco.gob.es/content/dam/mitesco/es/energia/files-1/balances/Balances/LibrosEnergia/Energia\\_2015.pdf](https://www.miteco.gob.es/content/dam/mitesco/es/energia/files-1/balances/Balances/LibrosEnergia/Energia_2015.pdf).
- [3] I. Dinov. “F Distribution Tables.” Consultado: 9 octubre, 2024. (2006), [En línea]. Disponible en: [http://www.socr.ucla.edu/Applets.dir/F\\_Table.html](http://www.socr.ucla.edu/Applets.dir/F_Table.html).
- [4] Altair. “ANOVA - Altair RapidMiner.” Consultado: 9 octubre, 2024. (2024), [En línea]. Disponible en: [https://docs.rapidminer.com/latest/studio/operators/validation/performance/significance\\_tests/anova.html](https://docs.rapidminer.com/latest/studio/operators/validation/performance/significance_tests/anova.html).